shadow_filter应用性能对比报告：RTX3090 vs 登临 KS20

测试时间：2026-02-10
对比项目：AI推理性能与管道延迟

1. 测试环境

- 基准环境：NVIDIA RTX3090 ， patch = 32
- 对比环境：登临科技 KS20 , patch = 2

2. 数据摘要（单位：ms）

基于最近连续运行的性能日志数据进行平均值计算。

指标	RTX3090（平均值）	KS20（平均值）	差异（ms）	性能提升（%）
平均管道延迟（Mean）	51.79	44.85	6.94	13.40%
P95 延迟（95th%）	71.21	63.46	7.75	10.89%
最大延迟（Max）	102.74	70.18	32.56	31.69%
平均 AI 推理耗时	30.29	24.31	5.98	19.74%

3. 详细分析

3.1 管道延迟（Pipeline Latency）

- 平均延迟：KS20 平均延迟 44.85 ms，比 RTX3090 快了 13.40%。
- 稳定性（P95）：KS20 的 P95 延迟优于 RTX3090（63.46 ms vs 71.21 ms），降低了 10.89%。
- 最大延迟：KS20最大延迟 70.18 ms，低于 RTX3090 的 102.74 ms，降低了 31.69%。

3.2 AI 推理性能（AI Inference）

- AI 耗时：KS20 平均耗时 24.31 ms，比 RTX3090（30.29 ms）快了 19.74%。

4. 结论

1. 在平均响应速度、最大延迟控制，AI 推理速度上，KS20 均优于 RTX3090。
2. KS20 将最大延迟压制在 70ms 左右，极好地消除了 RTX3090 上可能出现的 100ms+ 长尾延时导致的卡顿。
3. 本应用是基于yolo的图像二分类推理。模型参数规模很小，RTX3090具有10K核心，显存缓存大，适用于大参数大批次推理，对本应用的平衡patch = 32，生产时负载为20%左右。KS20在小批次 patch = 2 时

，负载为34%，推理速度快，延迟低，适用于实时场景。

4. KS20的延迟低，稳定，可满足实时监控的需求。若进一步优化，如量化到FP16甚至INT8，KS20的推理速度还可以有10-20的预计提升。但如果实施落地应用，还要进行nvenc视频硬件编码在KS20上的移植与性能评估。

附：原始日志数据摘录
RTX3090平台 (2026-01-13)

2026-01-13 14:22:57,21140,52.33,71.74,102.74,30.65 2026-01-13 14:22:58,21160,52.21,71.67,102.74,30.07 2026-01-13 14:22:59,21180,52.10,71.43,102.74,29.98 2026-01-13 14:22:59,21200,51.83,71.27,102.74,29.70 2026-01-13 14:23:00,21220,51.72,70.89,102.74,29.41 2026-01-13 14:23:01,21240,51.70,71.07,102.74,29.88 2026-01-13 14:23:02,21260,51.56,71.06,102.74,29.82 2026-01-13 14:23:03,21280,51.73,71.21,102.74,30.45 2026-01-13 14:23:04,21300,51.74,71.21,102.74,30.97 2026-01-13 14:23:04,21320,51.65,71.21,102.74,31.17 2026-01-13 14:23:05,21340,51.53,71.21,102.74,30.63 2026-01-13 14:23:06,21360,51.53,70.69,102.74,30.94 2026-01-13 14:23:07,21380,51.59,71.06,102.74,30.12

登临KS20 (最新 2026-02-10)

2026-02-10 15:11:12,2440,44.50,63.44,70.18,23.94 2026-02-10 15:11:13,2460,44.46,63.38,70.18,24.04 2026-02-10 15:11:14,2480,44.54,63.44,70.18,24.29 2026-02-10 15:11:14,2500,44.68,63.46,70.18,24.36 2026-02-10 15:11:15,2520,44.84,63.46,70.18,24.44 2026-02-10 15:11:16,2540,44.83,63.46,70.18,24.48 2026-02-10 15:11:17,2560,44.87,63.44,70.18,24.53 2026-02-10 15:11:18,2580,45.05,63.46,70.18,24.47 2026-02-10 15:11:19,2600,45.03,63.46,70.18,24.41 2026-02-10 15:11:19,2620,45.04,63.46,70.18,24.44 2026-02-10 15:11:20,2640,44.89,63.52,70.18,24.41 2026-02-10 15:11:21,2660,45.19,63.53,70.18,24.35 2026-02-10 15:11:22,2680,45.04,63.46,70.18,24.15 2026-02-10 15:11:23,2700,44.94,63.41,70.18,24.02